AKIVIAN

TECHNICAL NOTE

Deriving Alignment Algorithms from Scratch

Akivian · October 2026 · v1.0

Akivian/Principia-AI

QUESTION

Q：在已知人类相对偏好数据 $(x, y_w \succ y_l)$ 的情况下，如何以简洁直接的方式，训练模型生成更受偏好的回答?

记号与约定

1. 样本空间与数据

- $x \sim \mathcal{D}$：输入提示词，服从提示词分布 $\mathcal{D}$；
- $y \in \mathcal{Y}$：模型生成序列，$\mathcal{Y}$ 为所有候选输出序列构成的离散集合；
- $\mathcal{D}_{\text{pref}} = \left\{(x^{(i)}, y_w^{(i)}, y_l^{(i)})\right\}_{i=1}^{N}$：成对偏好数据集。对每个提示词 x，y_w 为人类更偏好的序列，y_l 为相对落选的序列。

2. 策略模型

- $\pi(y \mid x)$：给定提示词 x 时生成序列 y 的条件分布，满足：$\forall x,\ \sum_{y \in \mathcal{Y}} \pi(y \mid x) = 1$；
- π_θ：待优化的参数化策略（θ 为可训练参数）；
- π_{ref}：固定参考策略（多为监督微调后的初始模型），训练中参数冻结。

3. 辅助函数与常数

- $r(x, y) \in \mathbb{R}$：潜在标量奖励，衡量在提示词 x 下生成 y 的质量；
- $\beta > 0$：正则化强度，控制策略相对 π_{ref} 的偏离程度；
- $\sigma(z) = \frac{1}{1+e^{-z}}$：标准 Logistic 函数（Sigmoid）。

建模假设

Bradley–Terry 偏好模型：假设存在不可观测的真实奖励 $r^*(x, y)$，人类偏好服从该模型。 给定提示词 x，序列 y_w 优于 y_l 的概率定义为二者上的**二项 Softmax**（等价于 Sigmoid）：

$$P(y_w \succ y_l \mid x) \triangleq \frac{\exp(r^*(x, y_w))}{\exp(r^*(x, y_w)) + \exp(r^*(x, y_l))}$$

分子分母同除以 $\exp(r^*(x, y_w))$：

$$P(y_w \succ y_l \mid x) = \frac{1}{1 + \exp\Big(-(r^*(x, y_w) - r^*(x, y_l))\Big)} = \sigma\Big(r^*(x, y_w) - r^*(x, y_l)\Big)$$

预备引理

引理 1：吉布斯不等式（KL 散度非负性）

对任意离散概率分布 $P, Q \in \Delta(\mathcal{Y})$（满足 $\sum_y P(y) = \sum_y Q(y) = 1$）：

- **信息熵**：$H(P) \triangleq -\sum_{y \in \mathcal{Y}} P(y) \ln P(y)$（系统的平均信息量）；
- **交叉熵**：$H(P, Q) \triangleq -\sum_{y \in \mathcal{Y}} P(y) \ln Q(y)$（误用分布 Q 描述真实分布 P 时的平均代价）；
- **KL 散度（相对熵）**：

$$\mathbb{D}_{\mathrm{KL}}(P \parallel Q) \triangleq H(P, Q) - H(P)$$

$$= \sum_{y \in \mathcal{Y}} P(y) \ln \frac{P(y)}{Q(y)} \geq 0$$

> **【命题】** 对任意离散概率分布 $P, Q \in \Delta(\mathcal{Y})$，其 KL 散度 $\mathbb{D}_{\mathrm{KL}}(P \parallel Q) \triangleq \sum_y P(y) \ln \frac{P(y)}{Q(y)} \geq 0$，等号成立当且仅当 $\forall y, P(y) = Q(y)$。

【证明】 切线放缩：$\forall t > 0,\ \ln t \leq t - 1$ 原不等式等价于证：$\sum_y P(y) \ln \frac{Q(y)}{P(y)} \leq 0$ 由切线放缩：

$$\ln\left(\frac{Q(y)}{P(y)}\right) \leq \frac{Q(y)}{P(y)} - 1$$

两边同乘 $P(y) > 0$：

$$P(y) \ln\left(\frac{Q(y)}{P(y)}\right) \leq P(y)\left(\frac{Q(y)}{P(y)} - 1\right) = Q(y) - P(y)$$

全域求和：

$$\therefore \sum_{y\in\mathcal{Y}} P(y)\ln\left(\frac{Q(y)}{P(y)}\right) \le \sum_{y\in\mathcal{Y}}\Big(Q(y)-P(y)\Big) = \sum_{y\in\mathcal{Y}} Q(y) - \sum_{y\in\mathcal{Y}} P(y) = 1-1 = 0$$

$$\therefore -\sum_{y\in\mathcal{Y}} P(y)\ln\frac{P(y)}{Q(y)} \le 0$$

故：

$$\sum_{y\in\mathcal{Y}} P(y)\ln\frac{P(y)}{Q(y)} \ge 0 \iff \mathbb{D}_{\mathrm{KL}} \ge 0$$

由切线放缩取等条件知：当且仅当 $\forall y,\ \frac{Q(y)}{P(y)} = 1$，即 $Q(y) = P(y)$ 时取等。 ■

引理 2：KL 散度约束下的最优策略（吉布斯变分形式）

> **【命题】** 目标泛函 $\mathcal{J}(\pi) \triangleq \sum_y \pi(y\mid x) r(x,y) - \beta\,\mathbb{D}_{\mathrm{KL}}\Big(\pi(\cdot\mid x)\,\|\,\pi_{\mathrm{ref}}(\cdot\mid x)\Big)$ 在约束 $\sum_y \pi(y\mid x) = 1$ 下，存在全局最优解：
>
> $$\pi^*(y\mid x) = \frac{1}{Z(x)}\pi_{\mathrm{ref}}(y\mid x)\exp\left(\frac{1}{\beta}r(x,y)\right)$$
>
> 其中归一化函数 $Z(x) \triangleq \sum_y \pi_{\mathrm{ref}}(y\mid x)\exp\left(\frac{1}{\beta}r(x,y)\right)$。

【证明】 代入 KL 散度定义：

$$\mathcal{J}(\pi) = \sum_y \pi(y\mid x) r(x,y) - \beta\sum_y \pi(y\mid x)\ln\frac{\pi(y\mid x)}{\pi_{\mathrm{ref}}(y\mid x)}$$

$$= -\beta\left[\sum_y \pi(y\mid x)\ln\frac{\pi(y\mid x)}{\pi_{\mathrm{ref}}(y\mid x)} - \frac{1}{\beta}\sum_y \pi(y\mid x) r(x,y)\right]$$

$$= -\beta\left[\sum_y \pi(y\mid x)\left(\ln\frac{\pi(y\mid x)}{\pi_{\mathrm{ref}}(y\mid x)} - \frac{1}{\beta}r(x,y)\right)\right]$$

$$= -\beta\sum_y \pi(y\mid x)\left[\ln\frac{\pi(y\mid x)}{\pi_{\mathrm{ref}}(y\mid x)} - \ln\left(\exp\left(\frac{1}{\beta}r(x,y)\right)\right)\right]$$

$$= -\beta\sum_y \pi(y\mid x)\ln\frac{\pi(y\mid x)}{\pi_{\mathrm{ref}}(y\mid x)\exp\left(\frac{1}{\beta}r(x,y)\right)}$$

上式已接近 $\sum P(y)\ln\frac{P(y)}{Q(y)}$ 的 KL 散度形式，但分母尚未归一化。为直接调用引理 1 刻画极大值点，对分母进行配凑使之满足 $\sum Q(y)=1$： 定义分母各项之和为 $Z(x)\triangleq\sum_{y'}\pi_{\text{ref}}(y'\mid x)\exp\left(\frac{1}{\beta}r(x,y')\right)$； 定义归一化后合法概率分布 $\pi^*(y\mid x)\triangleq\frac{1}{Z(x)}\pi_{\text{ref}}(y\mid x)\exp\left(\frac{1}{\beta}r(x,y)\right)$；

$$\therefore\ \pi_{\text{ref}}(y\mid x)\exp\left(\frac{1}{\beta}r(x,y)\right)=Z(x)\cdot\pi^*(y\mid x)$$

代入上式：

$$\mathcal{J}(\pi)=-\beta\sum_y\pi(y\mid x)\ln\frac{\pi(y\mid x)}{Z(x)\cdot\pi^*(y\mid x)}$$

$$=-\beta\sum_y\pi(y\mid x)\left[\ln\frac{\pi(y\mid x)}{\pi^*(y\mid x)}-\ln Z(x)\right]$$

$$=-\beta\sum_y\pi(y\mid x)\ln\frac{\pi(y\mid x)}{\pi^*(y\mid x)}+\beta\sum_y\pi(y\mid x)\ln Z(x)$$

$$=-\beta\sum_y\pi(y\mid x)\ln\frac{\pi(y\mid x)}{\pi^*(y\mid x)}+\beta\ln Z(x)\underbrace{\sum_y\pi(y\mid x)}_{=1}$$

$$\therefore\ \mathcal{J}(\pi)=-\beta\,\mathbb{D}_{\text{KL}}\Big(\pi(\cdot\mid x)\parallel\pi^*(\cdot\mid x)\Big)+\beta\ln Z(x)\quad\text{（常数项）}$$

由引理 1，$\mathbb{D}_{\text{KL}}\Big(\pi(\cdot\mid x)\parallel\pi^*(\cdot\mid x)\Big)\geq 0$。

$\therefore$ 当且仅当 $\pi(y\mid x)=\pi^*(y\mid x)=\dfrac{1}{Z(x)}\pi_{\text{ref}}(y\mid x)\exp\left(\dfrac{1}{\beta}r(x,y)\right)$ 时，达到 $\mathcal{J}(\pi)$ 取最大值 $\beta\ln Z$

1. 出发点

1.1 无约束期望奖励最大化

设输入提示词 $x \sim \mathcal{D}$，候选生成序列 $y \in \mathcal{Y}$，参数化语言模型为条件概率分布 $\pi_\theta(\cdot \mid x) \in \Delta(\mathcal{Y})$，其中 $\Delta(\mathcal{Y})$ 表示离散概率单纯形。 设存在潜在标量奖励函数 $r(x, y) \in \mathbb{R}$。一个自然的优化目标是最大化策略在整个数据分布上的期望奖励：

$$\max_{\pi} \mathbb{E}_{x\sim\mathcal{D}} \left[\mathbb{E}_{y\sim\pi(\cdot|x)}[r(x,y)]\right] = \max_{\pi} \mathbb{E}_{x\sim\mathcal{D}} \left[\sum_{y\in\mathcal{Y}} \pi(y \mid x) r(x,y)\right]$$

$\because x$ 之间相互独立，全局期望最大化可逐步解耦为单样本优化问题：

$$\forall x \sim \mathcal{D}, \quad \max_{\pi(\cdot|x)\in\Delta(\mathcal{Y})} \sum_{y\in\mathcal{Y}} \pi(y \mid x) r(x,y) \quad \text{s.t. } \pi(y \mid x) \geq 0, \ \sum_{y\in\mathcal{Y}} \pi(y \mid x) = 1$$

然而，若直接用基础策略梯度（$\nabla_\theta \mathcal{J}_0 = \mathbb{E}[r \nabla_\theta \ln \pi_\theta]$）优化上述无约束目标，非常容易碰到：

- **Reward Hacking**
- **Mode Collapse**：过度集中于少数高奖励模式

在传统任务中，奖励函数多由奖励模型拟合，天然存在漏洞，故该思路实践意义有限；**然而，若把任务限制在可验证奖励范畴，用具有客观对错标准的形式化验证器替换 $r(x, y)$，也可以得到有趣的结果，例如 DeepSeek-R1-Zero**：

- 完全不依赖人类思维链数据（零监督微调），且不对参考策略施加 KL 散度约束（$\beta = 0$）；
- 直接在基座模型上，在去除 KL 散度惩罚（$\beta = 0$）的设定下，用组内相对优势做无约束强化学习；
- 随训练推进自发出现“长思考”（思维标记显著增多），并表现出类似元认知的自检行为：

  > *e.g. “Wait, wait, wait. That’s not right. Let me check again…”*

- 并可能以非人类习惯进行探索。

但该模型的问题也同样显而易见，并不意外：推理过程格式混乱，可读性低，容易陷入无限推理，且输出多语言混杂。

2. 正则约束下的在线优化

2.1 引入 KL 散度约束

为防止策略在最大化奖励时过度偏离，引入相对参考策略 $\pi_{\mathrm{ref}}(\cdot \mid x)$ 的 KL 散度作为罚项，得到带正则的目标：

$$\max_{\theta \in \mathbb{R}^d} \mathcal{J}(\theta; x) \triangleq \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) r(x, y) - \beta \mathbb{D}_{\mathrm{KL}}\Big(\pi_\theta(\cdot \mid x) \,\|\, \pi_{\mathrm{ref}}(\cdot \mid x)\Big)$$

其中，$\pi_\theta(\cdot \mid x) \in \Delta(\mathcal{Y})$ 为由参数 θ 控制的策略分布，$\Delta(\mathcal{Y})$ 为定义在离散序列空间 $\mathcal{Y}$ 上的概率单纯形，$\beta > 0$ 为正则化系数。

代入离散 KL 散度定义 $\mathbb{D}_{\mathrm{KL}}(P \,\|\, Q) \triangleq \sum_y P(y) \ln \frac{P(y)}{Q(y)}$，展开目标函数：

$$\mathcal{J}(\theta; x) = \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) r(x, y) - \beta \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) \ln \frac{\pi_\theta(y \mid x)}{\pi_{\mathrm{ref}}(y \mid x)}$$

注意到任务奖励项与 KL 散度惩罚项均以当前策略 $\pi_\theta(y \mid x)$ 作为概率测度，由数学期望线性性质，两项可直接合并为同一期望算子下的标量形式：

$$\mathcal{J}(\theta; x) = \mathbb{E}_{y \sim \pi_\theta(\cdot|x)} \left[r(x, y) - \beta \ln \frac{\pi_\theta(y \mid x)}{\pi_{\mathrm{ref}}(y \mid x)} \right] \triangleq \mathbb{E}_{y \sim \pi_\theta(\cdot|x)}[R_\theta(x, y)]$$

其中，$R_\theta(x, y)$ 为融合了 KL 散度正则的序列级奖励函数，定义为：

$$R_\theta(x, y) \triangleq r(x, y) - \beta \ln \frac{\pi_\theta(y \mid x)}{\pi_{\mathrm{ref}}(y \mid x)}$$

该合并显著降低采样开销。仅需单次在线自回归采样得到序列 $y \sim \pi_\theta$，即可完成两项计算。

然而，由于离散采样导致梯度断裂：

1. **采样算子不可微**：文本生成 $y \sim \pi_\theta$ 属于离散随机采样，该操作本身不可导，离散 token 无法把梯度回传到连续参数 θ；
2. **期望算子与求导算子不可交换**：期望 $\mathbb{E}_{y \sim \pi_\theta}[f(y)]$ 的积分测度是 π_θ 本身，而该分布依赖参数 θ。因此一般不能把 ∇_θ 直接移入期望内部，即

$$\nabla_\theta \mathbb{E}_{y \sim \pi_\theta}[f(y)] \neq \mathbb{E}_{y \sim \pi_\theta}[\nabla_\theta f(y)]$$

策略梯度定理正是为处理这一难点：将对参数的导数改写为对数概率加权形式，使梯度可在采样期望下估计。

2.2 策略梯度的推导

为求解 $\nabla_\theta \mathcal{J}(\theta; x)$，展开求和式并应用乘积求导法则：

$$\nabla_\theta \mathcal{J}(\theta; x) = \nabla_\theta \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) R_\theta(x, y) = \sum_{y \in \mathcal{Y}} \Big(\nabla_\theta \pi_\theta(y \mid x)\Big) R_\theta(x, y) + \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) \Big(\nabla_\theta R_\theta(x, y)\Big)$$

展开后半求和项：

$$\sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) \nabla_\theta \left(r(x, y) - \beta \ln \pi_\theta(y \mid x) + \beta \ln \pi_{\text{ref}}(y \mid x)\right)$$

$\because r(x, y) + \beta \ln \pi_{\text{ref}}(y \mid x)$ 均与 θ 无关

$$\therefore = \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) \cdot \Big(- \beta \nabla_\theta \ln \pi_\theta(y \mid x)\Big) = -\beta \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) \cdot \nabla_\theta \ln \pi_\theta(y \mid x)$$

又 $\because \nabla_\theta \ln f(\theta) = \frac{1}{f(\theta)} \cdot \nabla_\theta f(\theta)$

$$= -\beta \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) \cdot \frac{\nabla_\theta \pi_\theta(y \mid x)}{\pi_\theta(y \mid x)} = -\beta \sum_{y \in \mathcal{Y}} \nabla_\theta \pi_\theta(y \mid x) = -\beta \nabla_\theta \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x)$$

由全概率归一化：

$$= -\beta \nabla_\theta(1) = -\beta \cdot 0 \equiv \mathbf{0}$$

$\therefore$ 后半项由于全概率归一化而严格恒等于 0。 对前半项，应用对数导数恒等式 $\nabla_\theta \pi_\theta = \pi_\theta \nabla_\theta \ln \pi_\theta$ ：

$$\nabla_\theta \mathcal{J}(\theta; x) = \sum_{y \in \mathcal{Y}} \Big(\nabla_\theta \pi_\theta(y \mid x)\Big) R_\theta(x, y)$$

$$= \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x)\, R_\theta(x, y)\, \nabla_\theta \ln \pi_\theta(y \mid x)$$

$$= \mathbb{E}_{y \sim \pi_\theta(\cdot \mid x)} \left[R_\theta(x, y)\, \nabla_\theta \ln \pi_\theta(y \mid x)\right]$$

文本生成中 $\mathcal{Y}$ 搜索空间极大、无法遍历，故仅能使用蒙特卡洛采样。由上式，策略梯度已化为采样期望；对每次采得的 y，只需计算标量回报 $R_\theta(x,y)$ 与对数概率梯度，即可对该期望做无偏估计。

2.3 减小方差

然而，直接用蒙特卡洛抽样估计上述梯度，在离散文本空间中方差极大。 为此，引入与具体生成动作 y 无关的状态基线 $V(x)$。基线项的期望梯度严格恒为 0：

$$\mathbb{E}_{y\sim\pi_\theta}\left[V(x)\nabla_\theta \ln \pi_\theta(y \mid x)\right] = V(x)\sum_{y\in\mathcal{Y}}\nabla_\theta\pi_\theta(y \mid x) = V(x)\nabla_\theta(1) \equiv 0$$

若不减去基线，回报尺度往往整体偏正，优势函数偏弱的样本也会被同向强化，估计方差更大；减去与动作无关的基线后，优势函数更接近零均值，随机梯度更新更稳。按最小二乘意义，使梯度估计方差最小的基线，正是当前策略下的期望回报：

$$V^*(x) \triangleq \mathbb{E}_{y\sim\pi_\theta(\cdot|x)}[R_\theta(x,y)]$$

于是策略梯度可无偏地改写为以**优势函数**为权重的形式：

$$\nabla_\theta \mathcal{J}(\theta;x) = \mathbb{E}_{y\sim\pi_\theta(\cdot|x)}\left[A(x,y)\nabla_\theta \ln \pi_\theta(y \mid x)\right]$$

$$A(x,y) \triangleq R_\theta(x,y) - V(x)$$

然而，核心问题随即变为：如何构造 $V(x)$？ 要精确计算 $V^*(x)$，理论上需遍历 $\mathcal{Y}$ 中全部候选回答（规模约为 $|\mathcal{V}|^L$，极度冗余），并在训练中持续更新，实践中不可行。如何高效、低偏差地估计未知期望回报 $V^*(x)$，便成为在线强化学习的核心问题。

2.4 路线 A：价值网络与多步优势估计

面对高维空间中未知的期望回报 $V^*(x)$，一个自然想法是用参数化的**状态价值函数**去逼近。兼顾表征能力与计算量，可引入与策略网络规模相当的独立**价值网络** $V_\phi(s_t)$，用以拟合状态价值函数（即条件期望回报）：

$$V^{\pi_\theta}(s_t) \triangleq \mathbb{E}_{\pi_\theta}\left[\sum_{l=0}^{\infty}\gamma^l R_{t+l} \,\middle|\, s_t\right]$$

在 2.3 的推导中，方差最小的最优基线是当前策略下的期望回报。若把任务奖励记为 R_{task}（KL 项并入下文逐步奖励），则样本级最优基线可写为

$$b^*(x) \triangleq \mathbb{E}_{y\sim\pi_\theta}[R_{\text{task}}(x,y)]$$

然而，这在长序列生成中显然会带来归因困难：

- *例如*：一条含 T 个 token 的序列前 $T-1$ 步都正确，仅第 T 步算错，环境给出零奖励 $R_{\text{task}}(x,y)=0$。在整句标量基线下，整条序列的优势函数值均为负：

  $$0-b(x)<0$$

  该全局负信号会一并惩罚前 $T-1$ 步正确的局部决策，反之亦然。
- 同时，状态空间随长度 T 指数增长，完整轨迹的蒙特卡洛回报方差随长度累积，宏观基线 $b(x)$ 难以有效抑制轨迹内部 token 级扰动带来的方差。

马尔可夫决策过程建模

为定位导致最终成败的具体决策步，把文本生成写成离散时间马尔可夫决策过程：

- **状态空间** $\mathcal{S}$：至当前时刻的全部前缀 $s_t=(x,y_{<t})$，起始状态为 $s_1=(x)$；
- **动作空间** $\mathcal{A}$：词表中的下一 token $a_t=y_t\in\mathcal{V}$；
- **状态转移** P：确定性拼接 $s_{t+1}=(s_t\circ a_t)$；序列结束时引入虚拟终止状态 s_{T+1}，并约定状态价值函数满足 $V(s_{T+1})=0$；
- **单步奖励** R_t：在常见的“显式奖励 + 在线强化学习”设定中，中间步只承担 token 级分布偏离惩罚，终止步 $t=T$ 结算任务奖励 $R_{\text{task}}(x,y)$，并取折现因子 $\gamma=1$：

$$R_t(s_t,a_t)=\begin{cases}-\beta\ln\frac{\pi_\theta(a_t|s_t)}{\pi_{\text{ref}}(a_t|s_t)}, & 1\le t<T\\ R_{\text{task}}(x,y)-\beta\ln\frac{\pi_\theta(a_t|s_t)}{\pi_{\text{ref}}(a_t|s_t)}, & t=T\end{cases}$$

映射至该决策过程后，局部决策是否合理，便由**动作价值函数**与**状态价值函数**之差——**优势函数**——来衡量：

$$A^{\pi_\theta}(s_t,a_t)=Q^{\pi_\theta}(s_t,a_t)-V^{\pi_\theta}(s_t)$$

由于动作空间就是词表，该优势函数天然定义在 token 粒度上。

估计优势函数时，若直接用从当前时刻累加的经验回报 $G_t^{\text{MC}}\triangleq\sum_{l=0}^{T-t}\gamma^l R_{t+l}$，轨迹一长方差便过高；若只靠价值网络对状态价值函数做单步自举：

$$\hat{Q}(s_t,a_t)=R_t+\gamma V_{\phi,\text{old}}(s_{t+1})$$

虽能降低未来随机性带来的方差，却把价值网络对状态价值函数的逼近误差带进梯度。 定义单步时序差分残差为：

$$\delta_t \triangleq R_t + \gamma V_{\phi,\text{old}}(s_{t+1}) - V_{\phi,\text{old}}(s_t), \quad t \in \{1, 2, \dots, T\}$$

由 $V(s_{T+1}) = 0$，终止步残差为 $\delta_T = R_T - V_{\phi,\text{old}}(s_T)$。

偏差与方差的折中

为在“蒙特卡洛：高方差、低偏差”与“单步自举：低方差、高偏差”之间取得可控折中，把未来各步**时序差分残差**做指数加权求和，得到优势函数的**多步估计**。对长度为 T 的有限轨迹，约定终止后 $\delta_t = 0$（$t > T$），故

$$\hat{A}_t^{\text{GAE}(\gamma,\lambda)} \triangleq \sum_{l=0}^{T-t} (\gamma\lambda)^l \delta_{t+l}$$

- 当 $\lambda = 0$ 时，$\hat{A}_t^{\text{GAE}(\gamma,0)} = \delta_t$，仅依赖单步自举，方差最低，但对价值网络拟合状态价值函数时的偏差敏感；
- 当 $\lambda = 1$ 时，展开求和可得：

$$\hat{A}_t^{\text{GAE}(\gamma,1)} = \sum_{l=0}^{T-t} \gamma^l R_{t+l} + \gamma^{T-t+1} V_{\phi,\text{old}}(s_{T+1}) - V_{\phi,\text{old}}(s_t) = G_t^{\text{MC}} - V_{\phi,\text{old}}(s_t)$$

  此时退化为基于完整轨迹的蒙特卡洛优势函数估计：无偏，但方差随序列变长而显著增大。

得到上述优势函数估计后，下一步是用它更新策略网络与价值网络。
由策略梯度定理，更新应朝优势函数增大的方向进行。但训练样本来自旧策略 π_{old}，与当前 π_θ 有偏离，故引入重要性采样比

$$\rho_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\text{old}}(a_t \mid s_t)}$$

并以截断限制更新幅度，得到策略侧目标：

$$\mathcal{J}_{\text{PPO}}(\theta) = \mathbb{E}_{(s_t,a_t)\sim\pi_{\text{old}}} \left[\min \left(\rho_t(\theta) \hat{A}_t^{\text{GAE}},\ \text{clip}\big(\rho_t(\theta), 1-\epsilon, 1+\epsilon\big) \hat{A}_t^{\text{GAE}} \right) \right]$$

同时，价值网络将该优势函数估计与旧的状态价值函数估计合成目标回报 $\hat{G}_t \triangleq \hat{A}_t^{\text{GAE}}$

$+ V_{\phi,\text{old}}(s_t)$，用均方误差回归状态价值函数：

$$\mathcal{L}_V(\phi) = \mathbb{E}_{s_t}\left[\left(V_\phi(s_t) - \hat{G}_t\right)^2\right]$$

至此，针对 2.3 的基线估计问题，我们借助决策过程建模与价值网络，并在偏差—方差之间做权衡，给出了一条用参数化价值网络逼近状态价值函数的可行路径。

然而，在长思维链、大规模推理等场景下，该方案是否仍“高效且低偏差”？是否真正回答了 2.3 的核心问题?

上述以价值网络（逼近状态价值函数）与多步优势估计为核心的框架，在超大规模推理与长思维链面前有明显瓶颈：

- **系统开销与显存压力**：与策略网络规模相当的价值网络，再加上奖励模型与参考模型，带来额外显存与跨节点通信压力，制约上下文长度与并发；
- **环境往往不提供中间过程的密集信号**（例如仅终局可验证的任务）；
- **价值网络自身难收敛**：目标分布快速变化时，状态价值函数拟合困难，贝尔曼自举还会把误差逐步放大，价值函数估计可能崩溃。

2.5 路线 B：组内相对基线

回到 2.3 的结论：使方差最小的最优基线，就是当前采样分布下的期望回报：

$$b^*(x) = \mathbb{E}_{y\sim\pi_\theta}[R_{\text{task}}(x, y)]$$

既然用参数化价值网络估计 token 级状态价值函数 $V(s_t)$ 会带来归因困难，并付出显存与自举偏差的代价，一个更朴素的统计思路是：**不再跨分布去拟合全局期望；对给定提示词 x，在局部条件下采一组输出，用组内经验均值直接当该样本的基线，从而彻底去掉价值网络。**

对给定提示词 x，用当前旧策略 π_{old} 独立采出 G 条候选轨迹：

$$\mathcal{Y}_G = \{y_1, y_2, \dots, y_G\}, \quad y_i \sim \pi_{\text{old}}(\cdot \mid x)$$

再经规则验证器（面向数学、代码等可验证任务）给每条完整回答打标量任务奖励，得到 $\boldsymbol{R} = [R_1, R_2, \dots, R_G]^T$，其中 $R_i \triangleq R_{\text{task}}(x, y_i)$。

该提示词 x 在当前旧策略分布下的期望回报，由组内样本均值给出蒙特卡洛估计：

$$\text{mean}(\boldsymbol{R}) = \frac{1}{G}\sum_{i=1}^{G} R_i$$

同时计算组内样本标准差，以衡量当前问题下采样轨迹离散程度：

$$\mathrm{std}(\boldsymbol{R}) = \sqrt{\frac{1}{G}\sum_{i=1}^{G}\Big(R_i - \mathrm{mean}(\boldsymbol{R})\Big)^2 + \epsilon_{\mathrm{std}}}$$

其中 $\epsilon_{\mathrm{std}} > 0$（通常取 $10^{-6} \sim 10^{-4}$）用于维持数值稳定，防止组内奖励一致时除以零。

得到 G 条采样输出及其绝对奖励 $\{R_1, R_2, \dots, R_G\}$ 后，问题变为：如何用这些相对奖励更新策略?

直接最大化 $\mathbb{E}[R]$ 会像 2.3 一样：方差过大、训练震荡；不同提示词的奖励基线也相差很大，难以在统一尺度下稳定学习。

于是仍用组内均值 $\mathrm{mean}(\boldsymbol{R})$ 作基准，得到相对奖惩 $R_i - \mathrm{mean}(\boldsymbol{R})$。

但这尚未消除组内尺度差异——若某提示词组内波动极大，其梯度会主导参数更新。再除以组内标准差 $\mathrm{std}(\boldsymbol{R})$，得到组相对优势：

$$\tilde{A}_i = \frac{R_i - \mathrm{mean}(\boldsymbol{R})}{\mathrm{std}(\boldsymbol{R})}$$

然而，$\tilde{A}_i$ 是序列级标量，而策略梯度作用在 token 级（需计算 $\nabla_\theta \ln \pi_\theta(y_{i,t} \mid x, y_{i,<t})$）。

在 2.4 节，我们用价值网络为每个中间 token 估计状态价值函数 $V(s_t)$，再结合多步优势估计做细粒度归因；

本节既已去掉价值网络，便失去 token 级状态价值函数的估计能力，因而做出妥协：把整条序列的组相对优势 $\tilde{A}_i$ 平权广播到该回答的每一个生成 token：

$$\hat{A}_{i,t} = \tilde{A}_i, \quad \forall t \in \{1, \dots, |y_i|\}$$

以 token 级归因精度的损失，换取去掉价值网络后的显存收益，并消除自举偏差。

为把 token 级优势函数写成可优化目标，并复用旧策略 π_{old} 的采样，引入 token 级重要性采样比：

$$\rho_{i,t}(\theta) = \frac{\pi_\theta(y_{i,t} \mid x, y_{i,<t})}{\pi_{\mathrm{old}}(y_{i,t} \mid x, y_{i,<t})}$$

得到朴素代理目标 $\mathbb{E}\big[\rho_{i,t}(\theta)\tilde{A}_i\big]$。

然而，比率过大会引发梯度震荡，故沿用 2.4 节的截断约束：

$$\min\Big(\rho_{i,t}(\theta)\tilde{A}_i,\ \mathrm{clip}\Big(\rho_{i,t}(\theta), 1-\epsilon, 1+\epsilon\Big)\tilde{A}_i\Big)$$

同样需要 KL 散度正则，防止偏离参考模型 π_{ref}。

注意：在 2.1～2.4 中，KL 散度被写进决策过程的单步奖励再做多步优势估计；价值网络必须拟合“含 KL 散度约束”的状态价值函数（总回报），否则价值函数估计与真实目标（任务奖励 + KL 散度）错位，优势函数估计失效。

这加重了价值网络的拟合负担与自举误差：长序列上 KL 散度累积会带来巨大方差与长度偏差，冲淡任务奖励。

本节既无价值网络，也无单步递推与多步优势估计，便不必再把 KL 散度混进单步奖励。

于是把它挪到损失外层，作为独立正则项，避免不同轨迹长度下的累加污染组内标准差 $\text{std}(\boldsymbol{R})$，保证 $\tilde{A}_i$ 只反映任务相对优劣。

为削弱“越长序列累加项越多、越主导更新”的偏差，对序列内做长度归一化 $\frac{1}{|y_i|}\sum_{t=1}^{|y_i|}$，再在组内取平均，得到完整目标：

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{x,\{y_i\}}\left[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|y_i|}\sum_{t=1}^{|y_i|}\left\{\min\left(\rho_{i,t}(\theta)\tilde{A}_i,\ \text{clip}\big(\rho_{i,t}(\theta),1-\epsilon,1+\epsilon\big)\tilde{A}_i\right)-\beta D_{\text{KL}}^{(i,t)}\right\}\right]$$

该目标由策略优化项（由组相对优势 $\tilde{A}_i$ 驱动）与正则项（KL 散度控制偏离）组成。

构造 KL 散度估计器

计算 KL 散度项时，需要把它写成单样本可算的形式。

前向 KL 散度的期望写法为 $\mathbb{D}_{\text{KL}}(\pi_\theta \,\|\, \pi_{\text{ref}}) = \mathbb{E}_{\pi_\theta}[-\ln u]$，其中 $u = \frac{\pi_{\text{ref}}(y_{i,t})}{\pi_\theta(y_{i,t})} > 0$ 是逐 token 概率比。若直接用单样本 $-\ln u$ 做蒙特卡洛估计，其值可能为负，正则惩罚方向不稳定。

为使逐样本惩罚方向稳定且期望无偏，由引理 1 的切线放缩，构造逐样本非负估计器：

$$D_{\text{KL}}^{(i,t)} = u - \ln u - 1 \geq 0 \quad (\text{当且仅当 } u=1 \iff \pi_\theta = \pi_{\text{ref}} \text{ 时取等})$$

再验证其在期望意义下无偏：

$$\mathbb{E}_{\pi_\theta}[D_{\text{KL}}^{(i,t)}] = \mathbb{E}_{\pi_\theta}[u] - \mathbb{E}_{\pi_\theta}[\ln u] - 1$$

$$= \sum_a \pi_\theta(a)\frac{\pi_{\text{ref}}(a)}{\pi_\theta(a)} - \mathbb{E}_{\pi_\theta}\left[\ln\frac{\pi_{\text{ref}}}{\pi_\theta}\right] - 1$$

$$= \sum_a \pi_{\text{ref}}(a) - \mathbb{E}_{\pi_\theta}\left[\ln\frac{\pi_{\text{ref}}}{\pi_\theta}\right] - 1$$

$$= 1 + \mathbb{E}_{\pi_\theta}\left[-\ln \frac{\pi_{\text{ref}}}{\pi_\theta}\right] - 1$$

$$= \mathbb{D}_{\text{KL}}(\pi_\theta \,\|\, \pi_{\text{ref}})$$

这正是 Schulman 给出的 k_3 估计 `[Schulman, 2020]`。同文还有另外两种常用蒙特卡洛估计：

$$k_1 = \ln \frac{\pi_\theta}{\pi_{\text{ref}}}, \qquad k_2 = \frac{1}{2}\left(\ln \frac{\pi_\theta}{\pi_{\text{ref}}}\right)^2, \qquad k_3 = \frac{\pi_{\text{ref}}}{\pi_\theta} - \ln \frac{\pi_{\text{ref}}}{\pi_\theta} - 1$$

其中 k_1 无偏但可取负；k_2 恒非负、方差较低但有偏；k_3 同时无偏且逐样本非负，因而成为路线 B 中的默认选择。

至此，针对 2.3 的核心问题——如何高效、低偏差地估计期望回报 $b^*(x)$——本节给出更直观的统计解法：在局部分布下做组采样，用经验均值估计样本基线，为长程推理场景下的强化学习提供一条更省算力、更稳健的路径。

3. 跳出参数化

3.1 全局目标与逐点解耦

But, wait, wait, wait. Let us check again 让我们重新审视 2.1 一开始给出的目标函数：

$$\max_{\theta \in \mathbb{R}^d} \mathcal{J}(\theta; x) \triangleq \sum_{y \in \mathcal{Y}} \pi_\theta(y \mid x) r(x, y) - \beta\, \mathbb{D}_{\text{KL}}\Big(\pi_\theta(\cdot \mid x) \,\|\, \pi_{\text{ref}}(\cdot \mid x)\Big)$$

公式中存在一个明显的限制条件 “θ”：从一开始，我们就下意识地假定策略是一个由连续参数 $\theta \in \mathbb{R}^d$ 控制的神经网络 π_θ。 **然而，如果移除这一限制呢?**

$$\max_{\pi \in \Pi} \mathcal{J}_{\text{global}}(\pi) \triangleq \mathbb{E}_{x \sim \mathcal{D}}\left[\sum_{y \in \mathcal{Y}} \pi(y \mid x) r(x, y) - \beta\, \mathbb{D}_{\text{KL}}\Big(\pi(\cdot \mid x) \,\|\, \pi_{\text{ref}}(\cdot \mid x)\Big)\right]$$

其中相关空间与函数的形式化定义如下：

- **输入空间**：提示词空间 $\mathcal{X}$，其上附带先验概率测度 $x \sim \mathcal{D}$；
- **输出空间**：离散候选序列空间 $\mathcal{Y}$，其上的概率单纯形记为 $\Delta(\mathcal{Y})$；

- **条件策略全体**：

$$\Pi \triangleq \{\pi : \mathcal{X} \to \Delta(\mathcal{Y})\} = \prod_{x \in \mathcal{X}} \Delta(\mathcal{Y}) \quad (\Pi \text{ 为所有条件分布构成的笛卡尔积})$$

- **参考策略**：$\pi_{\text{ref}} \in \Pi$，具备全支撑（$\forall x \in \mathcal{X}, y \in \mathcal{Y},\ \pi_{\text{ref}}(y \mid x) > 0$）。

∵ 非参数化后，策略空间 Π 具备笛卡尔直积结构，各提示词 x 对应的条件分布 $\pi(\cdot \mid x)$ 彼此独立、无交叉约束，因此最大化全局期望等价于：对每一个 x，独立求解 $\mathcal{J}(\pi; x)$ 的极大值：

$$\pi^*(\cdot \mid x) = \arg \max_{\pi(\cdot|x) \in \Delta(\mathcal{Y})} \mathcal{J}(\pi; x)$$

其中条件目标为：

$$\mathcal{J}(\pi; x) \triangleq \sum_{y \in \mathcal{Y}} \pi(y \mid x) r(x, y) - \beta \sum_{y \in \mathcal{Y}} \pi(y \mid x) \ln \frac{\pi(y \mid x)}{\pi_{\text{ref}}(y \mid x)} \quad \text{s.t.} \ \sum_{y \in \mathcal{Y}} \pi(y \mid x) = 1,\ \pi(y \mid x) \geq 0$$

问题便化为固定上下文 x 下的代数极值问题。这意味着，可以通过代数变换直接求出最优策略 π^* 的解析解。

3.2 难以直接使用的闭式解

由引理 2，当且仅当：

$$\pi(y \mid x) = \pi^*(y \mid x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y \mid x) \exp\left(\frac{1}{\beta} r(x, y)\right) \text{ 时}$$

泛函 $\mathcal{J}(\pi)$ 取得极大值 $\beta \ln Z(x)$。

然而，虽然我们求出了最优策略的解析形式，却无法直接使用：

1. 奖励函数 $r(x, y)$ 缺乏解析表达；
2. $Z(x)$ 无法精确求解：输出空间 $\mathcal{Y}$ 的势为 $\mathcal{O}(|\mathcal{V}|^L)$（$|\mathcal{V}|$ 为词表大小，L 为序列长度），精确归一化在实践中不可行。

事实上，第 2 节的种种做法，正是在近似这一理论解析解。 既然 $r(x, y)$、$Z(x)$ 均无法精确表示或计算，这条路就走不通了吗?

让我们回到最初的问题与假设： 已知人类相对偏好数据 $\mathcal{D}_{\text{pref}} = \{(x, y_w, y_l)\}$。 假定人类在给定上下文 x 下对两个候选 (y_w, y_l) 的选择服从 Bradley–Terry 模型：

$$p^*(y_w \succ y_l \mid x) = \sigma\Big(r^*(x, y_w) - r^*(x, y_l)\Big), \quad \sigma(z) \triangleq \frac{1}{1 + e^{-z}}$$

又已知：

$$\pi^*(y \mid x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y \mid x) \exp\left(\frac{1}{\beta} r(x, y)\right)$$

4. 隐式奖励与极大似然

4.1 从点差法说起

于是最核心的问题是：
已知参考策略 $\pi_{\text{ref}}(y \mid x)$ 与偏好样本 $\mathcal{D}_{\text{pref}}$（其中蕴含对真实奖励 r^* 的偏好信息），分别有偏好模型与最优策略：

$$p^*(y_w \succ y_l \mid x) = \sigma\Big(r^*(x, y_w) - r^*(x, y_l)\Big) \qquad (\text{Pref})$$

$$\pi^*(y \mid x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y \mid x) \exp\left(\frac{1}{\beta} r(x, y)\right) \qquad (\text{Opt})$$

求仅关于 π^* 的方程。

相对关系？两式作差？——这让人想起高中圆锥曲线里的点差法： 已知方程 $\frac{x^2}{a^2} + \frac{y^2}{b^2} = 1$，两点 $A(x_1, y_1), B(x_2, y_2)$ 均在椭圆上，代入方程：

$$\begin{cases} \frac{x_1^2}{a^2} + \frac{y_1^2}{b^2} = 1 \\ \frac{x_2^2}{a^2} + \frac{y_2^2}{b^2} = 1 \end{cases}$$

两式相减消去右边常数：

$$\frac{(x_1 - x_2)(x_1 + x_2)}{a^2} + \frac{(y_1 - y_2)(y_1 + y_2)}{b^2} = 0$$

进一步得到 $k = \frac{y_1 - y_2}{x_1 - x_2} = -\frac{b^2}{a^2} \cdot \frac{x_1 + x_2}{y_1 + y_2}$，记中点坐标为 (x_0, y_0)，得 $k_{AB} \cdot \frac{y_0}{x_0} = -\frac{b^2}{a^2}$。

类似地，既然 $Z(x)$ 难以精确计算，且对 y 是常数，**是否可以用同样思路将其消去？**

4.2 反解隐式奖励并消去差分常数

对 (Opt) 两边同取自然对数：

$$\ln \pi^*(y \mid x) = \ln \left(\frac{1}{Z(x)} \pi_{\text{ref}}(y \mid x) \exp\left(\frac{1}{\beta} r(x,y) \right) \right) = \ln \pi_{\text{ref}}(y \mid x) + \frac{1}{\beta} r(x,y) - \ln Z(x)$$

整理可得：

$$r^*(x,y) = \beta \ln \left(\frac{\pi^*(y \mid x)}{\pi_{\text{ref}}(y \mid x)} \right) + \beta \ln Z(x)$$

故：

$$r^*(x,y_w) - r^*(x,y_l) = \left[\beta \ln \left(\frac{\pi^*(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} \right) + \beta \ln Z(x) \right] - \left[\beta \ln \left(\frac{\pi^*(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)} \right) + \beta \ln Z(x) \right]$$

$$= \beta \ln \left(\frac{\pi^*(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} \right) - \beta \ln \left(\frac{\pi^*(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)} \right)$$

代入 (Pref)：

$$p^*(y_w \succ y_l \mid x) = \sigma \left(\beta \ln \frac{\pi^*(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \ln \frac{\pi^*(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)} \right)$$

4.3 极大似然损失及其梯度

用参数化策略 π_θ 去拟合最优策略 π^*，把 π_θ 代入上述偏好式，得到模型预测的偏好概率：

$$P_\theta(y_w \succ y_l \mid x) \triangleq \sigma \left(\beta \ln \frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \ln \frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)} \right)$$

在偏好数据 $\mathcal{D}_{\text{pref}}$ 上做极大似然，优化 θ：

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) \triangleq -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}_{\text{pref}}} \left[\ln P_\theta(y_w \succ y_l \mid x) \right]$$

代入预测偏好概率，得到最终损失：

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}_{\text{pref}}} \left[\ln \sigma \left(\beta \ln \frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \ln \frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)} \right) \right]$$

再对 θ 求梯度，以分析该损失函数优化机制。定义模型隐式奖励：

$$\hat{r}_\theta(x, y) \triangleq \beta \ln \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}$$

利用 $\nabla_z \ln \sigma(z) = 1 - \sigma(z) = \sigma(-z)$ 做链式求导：

$$\nabla_\theta \mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x,y_w,y_l)} \left[\sigma\big(\hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w)\big) \cdot \nabla_\theta \left(\beta \ln \pi_\theta(y_w \mid x) - \beta \ln \pi_\theta(y_l \mid x) \right) \right]$$

$$= -\beta\, \mathbb{E}_{(x,y_w,y_l)} \left[\underbrace{\sigma\big(\hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w)\big)}_{\text{自适应权重 } w} \cdot \left(\underbrace{\nabla_\theta \ln \pi_\theta(y_w \mid x)}_{\text{提高胜出项概率}} - \underbrace{\nabla_\theta \ln \pi_\theta(y_l \mid x)}_{\text{压低失败项概率}} \right) \right]$$

该梯度有两个直观性质：

1. **更新方向明确**：沿拉高胜出项 y_w 概率、压低落选项 y_l 概率的方向更新；
2. **自适应加权**：前置权重 $w = \sigma(\hat{r}_l - \hat{r}_w)$ 度量当前预测偏差：

- 若模型当前完全判断错误 ($\hat{r}_l \gg \hat{r}_w$)，则 $w \to 1$，梯度较大、纠正力度大；
- 若模型已能很好区分偏好 ($\hat{r}_w \gg \hat{r}_l$)，则 $w \to 0$，梯度自然衰减，减轻过拟合。

5. 小结

至此，通过反解最优策略的解析形式，并借助 Bradley–Terry 偏好假设，我们得到一种与第 2 节“显式奖励 + 在线强化学习”在目标上数学等价的直接优化途径——前提是偏好服从该模型、真实奖励与最优策略一致，且在线目标下的最优策略与人类标签同向。借助“隐式奖励 + 离线监督”，便能以简洁直接的方式，用人类相对偏好数据训练模型生成更受偏好的回答，从而回答文首问题。

然而必须指出：第 3–4 节的方法建立在一系列理想化假设上：

1. **人类偏好服从 Bradley–Terry 模型**，即相对优劣由奖励差决定，且偏好具有传递性（真实数据却常有噪声与互相矛盾）；
2. **可实现性**：真实奖励落在奖励模型类内，最优策略 π^* 也能被策略模型表示（否则会出现设定失配）；
3. **最优策略与人类偏好同向**：第 4 节方法与第 2 节在线目标的等价性是有条件的；若不满足该隐含条件，优化目标便不再等价。

正因如此，第 2 节的在线强化学习路径在长推理训练中仍不可替代：它仍是促使模型自发回溯、反思与自我纠错，并有效利用测试时计算的重要手段。R1-Zero 等结果也提示：在可验证奖励设定

下，思维链是否好读，输出是否格式良好、语言统一，未必与任务表现同向。

对号入座

最后，揭晓前文所得结果的“真名”：

- **建模假设 • Bradley–Terry 偏好模型**：`[Bradley and Terry, 1952]`
- §1 **策略梯度与 REINFORCE**：`[Williams, 1992]`；**策略梯度定理**：`[Sutton et al., 1999]`
- §1.1 **DeepSeek-R1-Zero（零监督微调、可验证奖励上的大规模强化学习）**：`[DeepSeek-AI, 2025]`
- §2.4 **路线 A → PPO / RLHF**：
- **偏好强化学习**：`[Christiano et al., 2017]`
- **广义优势估计 (GAE)**：`[Schulman et al., 2016]`
- **近端策略优化 (PPO)**：`[Schulman et al., 2017]`
- **InstructGPT**：`[Ouyang et al., 2022]`
- §2.5 **路线 B → GRPO**：`[Shao et al., 2024]`
- §2.5 **逐 token KL 散度估计** k_1, k_2, k_3：`[Schulman, 2020]`
- §4 **隐式奖励与极大似然 → DPO**：`[Rafailov et al., 2023]`

感谢前辈们的探索与开拓。

参考文献

1. **Bradley, R. A., & Terry, M. E. (1952).** Rank analysis of incomplete block designs: I. The method of paired comparisons. *Biometrika, 39*(3/4), 324–345. https://doi.org/10.1093/biomet/39.3-4.324

2. **Williams, R. J. (1992).** Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning, 8*(3–4), 229–256. https://doi.org/10.1007/BF00992696

3. **Sutton, R. S., McAllester, D. A., Singh, S. P., & Mansour, Y. (1999).** Policy gradient methods for reinforcement learning with function approximation. In S. A. Solla, T. K. Leen, & K. Müller (Eds.), *Advances in Neural Information Processing Systems 12* (pp. 1057–1063). MIT Press. https://proceedings.neurips.cc/paper/1999/hash/464d828b85b0bed98e80ade0a5c43b0f-Abstract.html

4. **Schulman, J., Moritz, P., Levine, S., Jordan, M. I., & Abbeel, P. (2016).** High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations (ICLR)*. arXiv:1506.02438. https://arxiv.org/abs/1506.02438

5. **Christiano, P. F., Leike, J., Brown, T. B., Martic, M., Legg, S., & Amodei, D. (2017).** Deep reinforcement learning from human preferences. In I. Guyon et al. (Eds.), *Advances in Neural Information Processing Systems 30*. Curran Associates. arXiv:1706.03741. https://arxiv.org/abs/1706.03741

6. **Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017).** Proximal policy optimization algorithms. *arXiv preprint* arXiv:1707.06347. https://arxiv.org/abs/1707.06347

7. **Schulman, J. (2020, March 7).** Approximating KL divergence. http://joschu.net/blog/kl-approx.html

8. **Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Askell, A., Welinder, P., Christiano, P., Leike, J., & Lowe, R. (2022).** Training language models to follow instructions with human feedback. In S. Koyejo et al. (Eds.), *Advances in Neural Information Processing Systems 35*. Curran Associates. arXiv:2203.02155. https://arxiv.org/abs/2203.02155

9. **Rafailov, R., Sharma, A., Mitchell, E., Ermon, S., Manning, C. D., & Finn, C. (2023).** Direct preference optimization: Your language model is secretly a reward model. In A. Oh

et al. (Eds.), *Advances in Neural Information Processing Systems 36*. Curran Associates. arXiv:2305.18290. https://arxiv.org/abs/2305.18290

10. **Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y. K., Wu, Y., & Guo, D. (2024).** DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint* arXiv:2402.03300. https://arxiv.org/abs/2402.03300

11. **DeepSeek-AI. (2025).** DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning. *arXiv preprint* arXiv:2501.12948. https://arxiv.org/abs/2501.12948 另见正式出版版本：DeepSeek-AI et al. (2025). DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning. *Nature*. https://doi.org/10.1038/s41586-025-09422-z