AKIVIAN

TECHNICAL NOTE

Deriving Alignment Algorithms from Scratch

Akivian · October 2026 · v1.0

Akivian/Principia-AI

Deriving Alignment Algorithms from Scratch

No. github.com/Aktivian
Date repo: Principia-AI

Q: 在已知人类相对偏好数据 $(x, y_w \succ y_l)$ 的情况下，如何以简洁直接的方式，训练模型生成更受偏好的回答？

记号与约定

1. 样本空间与数据

$x \sim \mathcal{D}$：输入提示词，服从提示词分布 $\mathcal{D}$

$y \sim \mathcal{Y}$：模型生成序列，$\mathcal{Y}$ 为所有候选输出序列构成的离散集合

$\mathcal{D}_{pref} = \{(x^{(i)}, y_w^{(i)}, y_l^{(i)})\}_{i=1}^{N}$：离散成对偏好数据集，对每个 prompt x，y_w 表示人类偏好胜出序列（winner），y_l 表示被拒绝或失败序列（loser）

2. 策略模型（Policy）

$\pi(y|x)$：给定 prompt x 条件下生成序列 y 的概率分布，满足：$\forall x, \sum_{y \in \mathcal{Y}} \pi(y|x) = 1$

π_θ：待优化的参数化策略模型（θ 为神经网络可训练参数）

π_{ref}：固定的基准参考策略模型（通常为初始 SFT 模型），训练中参数冻结

3. 辅助函数与常数

$r(x, y) \in \mathbb{R}$：潜在标量奖励函数，衡量在提示词 x 下生成序列 y 的质量

$\beta > 0$：正则化系数（~~Temperature~~ KL惩罚系数），控制 π_{ref} 惩罚力度

$\sigma(z) = \frac{1}{1+e^{-z}}$：标准 Logistic Sigmoid 函数

建模假设

Bradley-Terry 偏好模型：假设存在不可观测的潜在真实奖励函数 $r^*(x, y)$，人类偏好服从 BT

给定提示词 x，序列 y_w 优于 y_l 的概率定义为两者的二分类 Softmax：

$$P(y_w \succ y_l | x) \triangleq \frac{\exp(r^*(x, y_w))}{\exp(r^*(x, y_w)) + \exp(r^*(x, y_l))}$$

分子分母同除 $\exp(r^*(x, y_w))$

$$P(y_w \succ y_l | x) = \frac{1}{1 + \exp(-(r^*(x, y_w) - r^*(x, y_l)))} = \sigma(r^*(x, y_w) - r^*(x, y_l))$$

KOKUYO

预备引理及其证明

引理1：吉布斯不等式（KL散度非负性定理）

对任意离散概率分布（分布：直观知道信息量）$P, Q \in \Delta(\mathcal{Y})$ $(\sum_y P(y) = \sum_y Q(y) = 1)$.

信息熵：$H(P) \triangleq -\sum_{y\in\mathcal{Y}} P(y)\ln P(y)$.

交叉熵：$H(P,Q) \triangleq -\sum_{y\in\mathcal{Y}} P(y)\ln Q(y)$（以用分布Q描述真实分布P时平均编码代价）

KL散度（相对熵）$\mathbb{D}_{KL}(P\|Q) \triangleq H(P,Q) - H(P)$

$$= \sum_{y\in\mathcal{Y}} P(y)(-\ln Q(y)) - \sum_{y\in\mathcal{Y}} P(y)(-\ln P(y))$$

$$= \sum_y P(y)\ln\frac{P(y)}{Q(y)} \geqslant 0$$

命题：对$\forall$离散概率分布$P, Q \in \Delta(\mathcal{Y})$，其KL散度$\mathbb{D}_{KL}(P\|Q) \triangleq \sum_y P(y)\ln\frac{P(y)}{Q(y)} \geqslant 0$，

等号成立当且仅当 $\forall y,\ P(y) = Q(y)$.

证：　切线放缩：$\ln t \leqslant t-1$

原式等价于证 $\sum_y P(y)\ln\frac{Q(y)}{P(y)} \leqslant 0$

由切线放缩 $\ln\left(\frac{Q(y)}{P(y)}\right) \leqslant \frac{Q(y)}{P(y)} - 1$

$$P(y)\ln\frac{Q(y)}{P(y)} \leqslant P(y)\cdot\left(\frac{Q(y)}{P(y)} - 1\right) = Q(y) - P(y)$$

$$\therefore \sum_{y\in\mathcal{Y}} P(y)\ln\left(\frac{Q(y)}{P(y)}\right) \leqslant \sum_{y\in\mathcal{Y}} Q(y) - P(y) = \sum_{y\in\mathcal{Y}} Q(y) - \sum_{y\in\mathcal{Y}} P(y) = 1 - 1 = 0$$

$$\therefore -\sum_{y\in\mathcal{Y}} P(y)\ln\frac{P(y)}{Q(y)} \leqslant 0$$

故 $\sum_{y\in\mathcal{Y}} P(y)\ln\frac{P(y)}{Q(y)} \geqslant 0 \Leftrightarrow \mathbb{D}_{KL} \geqslant 0$

由切线放缩取等条件知，

当且仅当 $\forall y\ \frac{Q(y)}{P(y)} = 1$，即 $Q(y) = P(y)$ 时取等.

引理2：KL约束下最优策略解析解（吉布斯变分定理）

命题：固标泛函 $J(\pi) \triangleq \sum_y \pi(y|x) r(x,y) - \beta \mathbb{D}_{KL}(\pi(y|x) \| \pi_{ref}(y|x))$ 在约束：

$\sum_y \pi(y|x) = 1$ 下，存在全局最优解：

$$\pi^*(y|x) = \frac{1}{Z(x)} \pi_{ref}(y|x) \exp\left(\frac{1}{\beta} r(x,y)\right)$$

其中归一化函数 $Z(x) \triangleq \sum_y \pi_{ref}(y|x) \exp\left(\frac{1}{\beta} r(x,y)\right)$

证：

代入KL散度定义：$J(\pi) = \sum_y \pi(y|x) r(x,y) - \beta \sum_y \pi(y|x) \ln \frac{\pi(y|x)}{\pi_{ref}(y|x)}$

$$= -\beta \left[\sum_y \pi(y|x) \ln \frac{\pi(y|x)}{\pi_{ref}(y|x)} - \frac{1}{\beta} \sum_y \pi(y|x) r(x,y) \right]$$

$$= -\beta \left[\sum_y \pi(y|x) \left[\ln \frac{\pi(y|x)}{\pi_{ref}(y|x)} - \frac{1}{\beta} r(x,y) \right] \right]$$

$$= -\beta \sum_y \pi(y|x) \left[\ln \frac{\pi(y|x)}{\pi_{ref}(y|x)} - \ln(\exp(\frac{1}{\beta} r(x,y)) \right]$$

$$= -\beta \sum_y \pi(y|x) \ln \frac{\pi(y|x)}{\pi_{ref}(y|x) \cdot \exp(\frac{1}{\beta} r(x,y))}$$

该式形式非常像 $\sum_y P(y) \ln \frac{P(y)}{Q(y)}$
如果分母满足 $\sum_y Q(y) = 1$
则可直接使用引理1得出极大值点性质

对分母强行配凑，使之归一化，满足引理1使用条件

定义分母各项之和为 $Z(x) \triangleq \sum_{y'} \pi_{ref}(y'|x) \exp\left(\frac{1}{\beta} r(x,y')\right)$

定义归一化后合法概率分布 $\pi^*(y|x) \triangleq \frac{1}{Z(x)} \cdot \pi_{ref}(y|x) \exp\left(\frac{1}{\beta} r(x,y)\right)$

$$\therefore \pi_{ref}(y|x) \cdot \exp\left(\frac{1}{\beta} r(x,y)\right) = Z(x) \cdot \pi^*(y|x)$$

$$\therefore J(\pi) = -\beta \sum_y \pi(y|x) \ln \frac{\pi(y|x)}{Z(x) \cdot \pi^*(y|x)}$$

$$= -\beta \sum_y \pi(y|x) \left[\ln \frac{\pi(y|x)}{\pi^*(y|x)} - \ln Z(x) \right]$$

$$= -\beta \sum_y \pi(y|x) \ln \frac{\pi(y|x)}{\pi^*(y|x)} + \beta \sum_y \pi(y|x) \ln Z(x)$$

$$= -\beta \sum_y \pi(y|x) \ln \frac{\pi(y|x)}{\pi^*(y|x)} + \beta \ln Z(x)$$

$$\therefore J(\pi) = -\beta \mathbb{D}_{KL}(\pi(y|x) \| \pi^*(y|x)) + \boxed{\beta \ln Z(x)} \text{ 常数}$$

由引理1，$\mathbb{D}_{KL}(\pi(y|x) \| \pi^*(y|x)) \geq 0$.

$\therefore$ 当且仅当 $\pi(y|x) = \pi^*(y|x) = \frac{1}{Z(x)} \cdot \pi_{ref}(y|x) \exp\left(\frac{1}{\beta} r(x,y)\right)$ 时，

泛函 $J(\pi)$ 取最大值 $\beta \ln Z(x)$

No. Akivian

Date

1.1

设输入提示词 $x\sim D$，候选生成序列 $y\in Y$，参数化语言模型为条件概率分布 $\pi_\theta(\cdot|x)\in\Delta(Y)$

其中 $\Delta(Y)$ 表示离散概率单纯形

设存在潜在标量奖励函数 $r(x,y)\in\mathbb{R}$

一个自然的优化目标是最大化策略在整个数据分布上的期望奖励：

$$\max_{\pi}\mathbb{E}_{x\sim D}\left[\mathbb{E}_{y\sim\pi(\cdot|x)}[r(x,y)]\right]=\max_{\pi}\mathbb{E}_{x\sim D}\left[\sum_{y\in Y}\pi(y|x)r(x,y)\right]$$

∵ x 之间相互独立，全局期望最大化可点态解耦为逐 x 单样本优化问题

$$\forall x\sim D,\ \max_{\pi(\cdot|x)}\sum_{y\in Y}\pi(y|x)r(x,y)\quad s.t.\ \pi(y|x)\geq 0,\ \sum_{y\in Y}\pi(y|x)=1$$

but. 若通过基础策略梯度机制（REINFORCE，$\nabla_\theta J_\theta=\mathbb{E}[r\nabla_\theta\ln\pi_\theta]$）直接优化上述无约束目标，非常容易碰到：

1> Reward Hacking

2> Mode Collapse

在传统任务中，由于 Reward 函数通常由奖励模型拟合（泛化误差易被过度利用），天然存在漏洞，故该思路落地价值较低，**but** 如果将任务限制在可验证奖励范畴，将 $r(x,y)$ 替换为具客观判别准则的形式化验证器，也可以产出有趣的结果，比如 **DeepSeek-R1-Zero**

该模型完全不依赖人类 CoT 微调（Zero SFT），且不对参考策略做 KL 散度约束（$\beta=0$）

直接在 Base Model 上，应用去除 KL 惩罚（$\beta=0$）的 GRPO 进行无约束 RL

模型随训练步数推进自发学会了"长思考"（Thinking Tokens 爆长），并涌现出元认知：

e.g. "Wait, wait, wait. That's not right. Let me check again..."

并且会使用非人类习惯的探索路径。

但该模型的问题也同样明显且"符合预期"，推理过程格式混乱，可读性低，容易陷入无限推理且输出多语言混杂。tips：自然语言真的是模型进行内部推理和相互通讯的最佳媒介？这种"AI Slop"是否是某种尚未被人类定义和约束的"内部符号系统"

显然在代码生成、安全对抗领域，我们有明确的方法判定是否"有效"

所谓的"可读性"是否还真正重要？甚至其实"有害"？

KOKUYO

2.1

为防止策略在最大化奖励时发生过度偏移，引入相对于参考策略 $\pi_{ref}(\cdot|x)$ 的KL散度作为正则化惩罚项，由此构建带罚项的目标函数

$$\max_{\theta\in\mathbb{R}^d} J(\theta;x) \triangleq \sum_{y\in\mathcal{Y}} \pi_\theta(y|x) r(x,y) - \beta \mathbb{D}_{KL}(\pi_\theta(\cdot|x) \| \pi_{ref}(\cdot|x))$$

其中，$\pi_\theta(\cdot|x) \in \Delta(\mathcal{Y})$ 为由参数 θ 控制的策略分布，$\Delta(\mathcal{Y})$ 为定义在离散序列空间的 $\mathcal{Y}$ 上的单纯形，$\beta>0$ 为正则化系数。

代入离散相对熵定义 $\mathbb{D}_{KL}(P\|Q) \triangleq \sum_y P(y) \ln \frac{P(y)}{Q(y)}$，展开目标函数

$$J(\theta;x) = \sum_{y\in\mathcal{Y}} \pi_\theta(y|x) r(x,y) - \beta \sum_{y\in\mathcal{Y}} \pi_\theta(y|x) \ln \frac{\pi_\theta(y|x)}{\pi_{ref}(y|x)}$$

注意到任务奖励项与相对熵惩罚项均以当前策略 $\pi_\theta(y|x)$ 作为概率测度。由数学期望线性性质，两项可直接合并为同一期望算子下的标量形式

$$J(\theta;x) = \mathbb{E}_{y\sim\pi_\theta(\cdot|x)}\left[r(x,y) - \beta \ln \frac{\pi_\theta(y|x)}{\pi_{ref}(y|x)}\right] \triangleq \mathbb{E}_{y\sim\pi_\theta(\cdot|x)}[R_\theta(x,y)]$$

其中，$R_\theta(x,y)$ 为融合了KL正则化惩罚的序列级奖励函数，定义为

$$R_\theta(x,y) \triangleq r(x,y) - \beta \ln \frac{\pi_\theta(y|x)}{\pi_{ref}(y|x)}$$

该合并显著降低采样开销。仅需单次在线自回归采样得到序列 $y\sim\pi_\theta$，即可完成两项计算。

but 由于：

1）~~采样算子不可导~~离散采样导致梯度断裂：文本生成 $y\sim\pi_\theta$ 属离散随机采样，该样本自不可导，序列token索引无法将梯度回传至连续参数 θ

2）期望算子与求导算子不可交换：期望本质上是以 π_θ 为概率测度的积分，由于积分测度本身是参数 θ 的函数，因此 $\nabla_\theta \mathbb{E}_{y\sim\pi_\theta}[f(y)] \neq \mathbb{E}_{y\sim\pi_\theta}[\nabla_\theta f(y)]$，须通过策略梯度定理（REINFORCE技巧）将测度对参数的导数转化为对数几率形式

No. Akivion

Date

2.2

为求解 $\nabla_\theta J(\theta;x)$，展开求和式并应用乘积求导法则

$$\nabla_\theta J(\theta;x) = \nabla_\theta \sum_{y\in Y} \pi_\theta(y|x) R_\theta(x,y) = \sum_{y\in Y} (\nabla_\theta \pi_\theta(y|x)) R_\theta(x,y) + \sum_{y\in Y} \pi_\theta(y|x)(\nabla_\theta R_\theta(x,y))$$

展开后半求和项：

$$\sum_{y\in Y} \pi_\theta(y|x) \nabla_\theta (r(x,y) - \beta \ln \pi_\theta(y|x) + \beta \ln \pi_{ref}(y|x))$$

$\because r(x,y) + \beta \ln \pi_{ref}(y|x)$ 均与 θ 无关

$$\therefore = \sum_{y\in Y} \pi_\theta(y|x) \cdot (-\beta \nabla_\theta \ln \pi_\theta(y|x))$$

$$= -\beta \sum_{y\in Y} \pi_\theta(y|x) \cdot \nabla_\theta \ln \pi_\theta(y|x)$$

又 $\because \nabla_\theta \ln f(\theta) = \frac{1}{f(\theta)} \cdot \nabla_\theta f(\theta)$

$$= -\beta \sum_{y\in Y} \pi_\theta(y|x) \cdot \frac{\nabla_\theta \pi_\theta(y|x)}{\pi_\theta(y|x)} = -\beta \sum_{y\in Y} \nabla_\theta \pi_\theta(y|x)$$

$$= -\beta \nabla_\theta \sum_{y\in Y} \pi_\theta(y|x)$$

由全概率归一化 $= -\beta \nabla_\theta(1) = -\beta \cdot 0 \equiv 0$

tips：由于文本生成中，y的空间极大无法遍历
使用蒙特卡洛采样
但对于采样出的y，手里只有 $\pi_\theta(y|x)$ 和 $R(x,y)$
无法求出 $\nabla_\theta \pi_\theta$.
所以需手动写出一个“在 π_θ 概率分布下的期望形式”
$\mathbb{E}_{y\sim\pi_\theta}[f(y)]$

$\therefore$ 后半项由于全概率归一化而严格恒等于0，$\nabla_\theta J(\theta;x) = \sum_{y\in Y} (\nabla_\theta \pi_\theta(y|x)) R_\theta(x,y)$

对前半项，应用对数导数恒等式 $\nabla_\theta \pi_\theta = \pi_\theta \nabla_\theta \ln \pi_\theta$

$$\nabla_\theta J(\theta;x) = \sum_{y\in Y} (\pi_\theta(y|x) \cdot \nabla_\theta \ln(\pi_\theta(y|x)) R_\theta(x,y) = \mathbb{E}_{y\sim\pi_\theta(\cdot|x)} [R_\theta(x,y) \nabla_\theta \ln \pi_\theta(y|x)]$$

该式使得梯度可以通过蒙特卡洛采样计算

2.3

but，直接通过蒙特卡洛抽样计算上述梯度，在高维文本空间中面临巨大估计方差。为此，引入一个与具体生成动作 y 无关的状态基线函数（Baseline）$V(x)$。由于基线项的期望梯度严格恒为零：

tips：如果不减去 baseline，得到的 R 总是正的（奖励分），即使是烂答案，模型也会提高其概率。但 SGD 的核心假设是梯度的噪声是零均值的

$$\mathbb{E}_{y\sim\pi_\theta} [V(x) \nabla_\theta \ln \pi_\theta(y|x)] = V(x) \sum_{y\in Y} \nabla_\theta \pi_\theta(y|x) = V(x) \nabla_\theta(1) = 0$$

由最小二乘估计，能使梯度估计方差最小的基线，为当前策略下期望回报

$$V^{\pi_\theta}(x) \triangleq \mathbb{E}_{y\sim\pi_\theta(\cdot|x)} [R_\theta(x,y)]$$

KOKUYO

策略梯度可先偏重构为以优势函数(Advantage Function)为权重的形式:

$$\nabla_\theta J(\theta;x)=\mathbb{E}_{y\sim\pi_\theta(\cdot|x)}[A(x,y)\nabla_\theta\ln\pi_\theta(y|x)]$$

$$A(x,y)\triangleq R_\theta(x,y)-V(x)$$

but,这又引出了一个核心问题:如何构造 $V(x)$?

要精确计算 $V^\pi(x)$,理论上需要遍历序列空间 $\mathcal{Y}$ 中所有可能回答(大小约为 $|V|^{|y|}$ 的指数级空间),且策略 π_θ 在训练中持续更新,因此在实践中不可行.如何高效且低偏差地估计未知期望回报 $V^\pi(x)$ 成为在线RL的核心问题

2.4

面对高维空间中的未知期望回报 $V^\pi(x)$,一个自然的想法是使用参数化函数(神经网络)逼近.考虑到表达与计算量,具体而言,应引入一个与生成模型(Actor)参数量相当、表征能力对等的独立神经网络(Critic $V_\theta(S_t)$),拟合期望回报

$$V^{\pi_\theta}(S_t)\triangleq\mathbb{E}_{\pi_\theta}\left[\sum_{l=0}^{T-t}\gamma^l R_{t+l}\middle|S_t\right]$$

在2.3的推导中,方差最小的最优基线形式化在输入样本级: $b^*(x)\triangleq\mathbb{E}_{y\sim\pi_\theta}[R_{task}(x,y)]$

but,这在长序列生成中显然会导致信用分配问题:

(i) 一条包含T个token序列前T-1步严格正确,仅第T步出现符号/计算错误.

环境给出零奖励 $R_{task}(x,y)=0$,在整句标量基线下,整条序列的优势均为负:

$$0-b(x)<0.$$

该全局负信号会均等惩罚前T-1步正确的中间决策,反之亦然,

同时生成序列的状态-动作空间随长度T指数增长,完整轨迹的蒙特卡洛回报方差随序列长度累积,宏观基线 $b(x)$ 难以降低轨迹内部token级扰动导致的方差累积

为定位导致最终成败的具体决策步，需将文本生成形式化为离散时间马尔可夫决策过程(MDP)：

- 状态空间S：至当前时刻的全部前缀上下文 $S_t=(x, y_{<t})$，其中起始状态为 $S_1=(x)$；
- 动作空间A：词表中的下一 token 选取 $a_t=y_t \in V$；

  状态转移P：确定性字符串拼接 $S_{t+1}=(S_t \circ a_t)$，并定义序列终结时的虚拟终止状态 S_{T+1}，其价值恒满足 $V(S_{T+1})=0$；
- 单步奖励 R_t：在标准RLHF设定中，中间步承担 token 级分布偏移惩罚，终止步 $t=T$ 结算任务奖励 $R_{task}(x,y)$，约定折扣因子 $\gamma=1$；

$$R_t(S_t, a_t)=\begin{cases}-\beta \ln \frac{\pi_\theta(a_t|S_t)}{\pi_{ref}(a_t|S_t)} & 1\le t<T \\ R_{task}(x,y)-\beta \ln \frac{\pi_\theta(a_t|S_t)}{\pi_{ref}(a_t|S_t)} & t=T\end{cases}$$

将任务映射至MDP后，评估局部决策合理性的标准转化为动作价值为不再是整句成败，而是动作优势函数：

$$A^{\pi_\theta}(S_t, a_t)=Q^{\pi_\theta}(S_t, a_t)-V^{\pi_\theta}(S_t).$$

由于动作空间为词表，该优势函数天然在 token 粒度上定义

为估计动作优势，若直接采用从当前时刻起累积的经验回报 $G_t^{MC} \triangleq \sum_{l=0}^{T-t} \gamma^l R_{t+l}$ 会因轨迹过长导致方差过高。若仅依靠参数化价值网络的单步自举：

$$\hat{Q}(S_t, a_t)=R_t+\gamma V_{\phi_{old}}(S_{t+1})$$

虽能消除采样随机性，却为将价值网络自身逼近误差引入梯度计算。

定义旧价值网络 $V_{\phi_{old}}(S_{t+1})$ 下单步时序(TD)残差为：

$$\delta_t \triangleq R_t+\gamma V_{\phi_{old}}(S_{t+1})-V_{\phi_{old}}(S_t),\ t\in\{1,2,\cdots T\}$$

由于约定 $V(S_{T+1})=0$，终止步残差为 $\delta_T^V=R_T-V_{\phi_{old}}(S_T)$

No. Akivian

Date

为在蒙特卡洛估计的"零偏差、高方差"与单步自举的"低方差、高方差"之间取得可控权衡，引入广义优势估计，其定义为未来各阶时序差分残差的指数加权和.

$$A_t^{GAE(\gamma,\lambda)} \triangleq \sum_{l=0}^{T-t} (\gamma\lambda)^l \delta_{t+l}$$

当 $\lambda=0$ 时，$\hat{A}_t^{GAE(\gamma,\lambda)} = \delta_t^V$，仅依赖单步自举，方差最低，但对价值网络拟合偏差敏感

当 $\lambda=1$ 时，错位相消展开和式可得：

$$\hat{A}_t^{GAE} = \sum_{l=0}^{T-t} \gamma^l R_{t+l} + \gamma^{T-t+1} V_{\theta old}(S_{T+1}) - V_{\theta old}(S_t) = G_t^{MC} - V_{\theta old}(S_t),$$

此时 GAE 退化为基于完整轨迹的蒙特卡洛优势估计，该估计无偏，但方差随序列长度增加显著增大

通过 GAE 得到优势函数估计 $\hat{A}_t^{GAE}$ 后，接下来的问题是如何利用该优势估计更新策略网络与价值网络

由策略梯度定理，策略更新应朝向优势增大方向，但由于训练数据由旧策略 $\pi_{\theta old}$ 采样，与当前策略 π_θ 存在偏移，需引入重要性采样比并进行修正（并通过截断机制约束策略更新幅度）得到 Actor 目标函数

$$J_{PPO}(\theta) = \mathbb{E}_{(S_t,a_t)\sim\pi_{\theta old}}\left[\min\left(\rho_t(\theta)\hat{A}_t^{GAE},\ clip(\rho_t(\theta),1-\epsilon,1+\epsilon)\hat{A}_t^{GAE}\right)\right]$$

同时，Critic 利用该优势估计与旧价值基线合成目标回报 $\hat{G}_t \triangleq \hat{A}_t^{GAE} + V_{\theta old}(S_t)$，通过均方误差进行回归：

$$L_{Critic}(\phi) = \mathbb{E}_{S_t}\left[(V_\phi(S_t) - \hat{G}_t)^2\right]$$

至此，针对 2.3 提出的基线估计问题，我们通过 MDP 建模、显式价值网络与 GAE 权衡，成功给出了一套基于参数化价值网络（Critic）的可行实现路径.

but，对于 LLM 长思维链（Long CoT）、大规模推理等场景，该方案是否"高效且低偏差"是否真正回答了 2.3 提出的核心问题？

KOKUYO

上述以参数化 Critic 和 GAE 为核心的框架，在面对超大规模推理模型及 Long CoT 时，存在明显瓶颈：

- **系统开销与显存压力**：与 Actor 参数规模持平的 Critic，再加上 Reward 和 Reference，带来数张卡的内存开销与跨节点通讯压力，制约最长上下文与并发规模
- **环境（如 RLVR）不提供中间过程监督信号**
- **Critic 自身难收敛**：在目标分布快速变化的情况下，Critic 收敛难度大，且 Bellman 自举会将 Critic 拟合偏差逐步传递并放大，进而导致价值估计发散

2.5

回到 2.3 节推导所得结论：使方差最小的最优基线即当前条件下状态的条件期望回报：

$$b^*(x) = \mathbb{E}_{y\sim\pi_\theta}[R_{task}(x,y)]$$

既然用参数化 Critic 估计 token 级价值 $V(s_t)$ 会引入信用分配问题并进一步带来显存开销与自举偏差代价，一个统计学上更直接的思路是：**放弃跨分布拟合全局期望，对于给定的具体输入提示词 x，在局部条件下采样一组输出，以组内经验均值直接充当该样本基线，彻底剥离 Critic 网络**

针对给定的提示词输入 $q\sim P(Q)$，利用当前旧策略 $\pi_{\theta_{old}}$ 独立并发采样出一组规模为 G 的候选输出轨迹

$$O=\{o_1,o_2,\cdots o_G\},\quad o_i\sim\pi_{\theta_{old}}(\cdot|q)$$

经由规则验证系统（针对数学、代码等 RLVR 任务）充当判别器，对组内每个完整回答给出标量化为奖励，形成奖励向量 $R=[R_1,R_2\cdots,R_G]^T$，其中 $R_i\triangleq R_{task}(q,o_i)$

该输入 q 在当前旧策略分布下的期望回报，由组内样本均值给出蒙特卡洛估计

$$mean(R)=\frac{1}{G}\sum_{i=1}^{G}R_i$$

同时计算组内样本标准差，以衡量当前问题下采样轨迹性能离散程度：

$$std(R)=\sqrt{\frac{1}{G}\sum_{i=1}^{G}(R_i-mean(R))^2}+\varepsilon_{std}$$

其中 $\varepsilon_{std}>0$（通常取 $10^{-6}\sim10^{-4}$）为维持数值稳定性正则化扰动，防止组内奖励一致时除以0.

得到G个采样输出及其绝对奖励 $\{R_1,R_2\cdots R_G\}$，现在的问题是：如何利用这些绝对奖励来更新策略 π_θ？

直接的策略优化思路是最大化期望奖励 $\mathbb{E}[R]$，但和2.3碰到的问题一样：①无差别无导致训练浪费 ②不同prompt奖励基线（无差 VS 基础），模型为倾向于学习简单任务。

同样的思路，引入组内均值 $mean(R)$ 作为基线，得到相对奖励：

$$R_i-mean(R)$$

但这仍未解决组内方差尺度的差异，若某组Prompt内组内差异极大，其梯度将主导参数更新。为此进一步除以组内标准差 $std(R)$，构造组相对优势

$$\tilde{A}_i=\frac{R_i-mean(R)}{std(R)}$$

but, $\tilde{A}_i$ 为序列级标量，模型策略梯度又新作用于token级（需计算每个生成词元的对数概率梯度 $\nabla_\theta\log\pi_\theta(o_{i,t}|q,o_{i,<t})$）

在2.4节，我们通过 Critic 网络弥补该 gap：Critic为每个中间词token估计价值 $V(s_t,t)$，结合广义奖励计算广义优势估计(GAE)实现细粒度时序信用分配

but，在本节我们剥离了Critic网络，失去了估计token级价值的能力，故似出乎动：将整条序列的组相对优势 $\tilde{A}_i$ 平权广播至该回答的所有生成token：

$$\hat{A}_{i,t}=\tilde{A}_i,\quad \forall t\in\{1,\cdots,|o_i|\}$$

以token归因精度的损失，获取剥离Critic网络带来的巨大显存收益与自举偏差的消除

为将 token 级优势 $\hat{A}_{i,t}$ 转化为可优化损失，并复用旧策略 $\pi_{\theta_{old}}$ 的采样数据以提高效率，引入 token 级重要性采样比率

$$\rho_{i,t}(\theta)=\frac{\pi_\theta(o_{i,t}|q,o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t}|q,o_{i,<t})}$$

得到带采样理因标：$E[\rho_{i,t}(\theta)\tilde{A}_i]$。

but，比率过大会引发梯度发散，故引入 2.4 节的信赖域裁剪(机制)：

$$\min\left(\rho_{i,t}(\theta)\tilde{A}_i,\ clip(\rho_{i,t}(\theta),1-\epsilon,1+\epsilon)\tilde{A}_i\right)$$

同样，也需要引入 KL 正则化约束以防其不偏离参考模型 π_{ref}

这里需要注意，在 2.1~2.4 节的推导中，由于是 MDP 和单步奖励进行 GAE，为通过单步自举计算 token 级优势，Critic 须拟合“带 KL 约束”的总回报，若 KL 不入奖励，Critic 的价值估计将与实际优化目标（任务奖励 + KL 约束端位）致 GAE 失效

but，这也会导 Critic 拟合难度与自举误差增大（长序列 KL 累积引发巨大方差与长度偏差），此任务奖励信号被稀释

but，在本节我们彻底剥离了 critic，亦没有 MDP 单步建模与 GAE，也就失去了将 KL 混入单步奖励的必要性。

故将 KL 移至 Loss 外层，作为独立正则项，避免不同轨迹长度下 KL 累加惩罚对组内方差 std(R) 的污染，确保 A_i 纯粹源于，同时仅 KL 正则项独立发挥作用

为消除长序列因累加项过多而主导更新的偏差，对序列内部进行长度归一化，$\frac{1}{|o_i|}\sum_{t=1}^{|o_i|}$，并在组内求均值。

最终得到完整目标函数

$$J_{GRPO}(\theta)=\mathbb{E}_{q,\{o_i\}}\left[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|}\left\{\min\left(\rho_{i,t}(\theta)\tilde{A}_i,\ clip(\rho_{i,t},1-\epsilon,1+\epsilon)\tilde{A}_i\right)-\beta D_{KL}^{(i,t)}\right\}\right]$$

目标函数 J_{GRPO} 由策略文新项（利用优势函数 A_i 驱动）与正则化项（KL 散度）共同驱动

对于KL项的计算，需将其转化为单样本可计算形式

前向KL散度的期望形式为 $\mathbb{D}_{KL}(\pi_\theta \| \pi_{ref}) = \mathbb{E}_{\pi_\theta}[-\ln u]$，其中 $u = \frac{\pi_{ref}(o_t,t)}{\pi_\theta(o_t,t)} > 0$，为逐token概率比值。若直接以单样本 $-\ln u$ 进行蒙特卡洛估计，其值可能为负，导致正则化惩罚方向不稳定。

为保证逐样本惩罚方向稳定且期望无偏，由引理1切线放缩，构造逐样本非负估计器

$$D_{KL}^{(t,t)} = u - \ln u - 1 \geq 0$$

（当且仅当 $u=1 \Leftrightarrow \pi_\theta = \pi_{ref}$ 时取等）

进一步验证该估计器在期望意义上无偏性：

$$\begin{aligned}
\mathbb{E}_{\pi_\theta}[D_{KL}^{(t,t)}] &= \mathbb{E}_{\pi_\theta}[u] - \mathbb{E}_{\pi_\theta}[\ln u] - 1 \\
&= \sum_a \pi_\theta(a) \frac{\pi_{ref}(a)}{\pi_\theta(a)} - \mathbb{E}_{\pi_\theta}\left[\ln \frac{\pi_{ref}}{\pi_\theta}\right] - 1 \\
&= \sum_a \pi_{ref}(a) - \mathbb{E}_{\pi_\theta}\left[\ln \frac{\pi_{ref}}{\pi_\theta}\right] - 1 \\
&= 1 + \mathbb{E}_{\pi_\theta}\left[-\ln \frac{\pi_{ref}}{\pi_\theta}\right] - 1 \\
&= \mathbb{D}_{KL}(\pi_\theta \| \pi_{ref})
\end{aligned}$$

注 John Schulman 总结的三种KL估计器为

$k_1 = \ln \frac{\pi_\theta}{\pi_{ref}}$

$k_2 = \frac{1}{2}(\ln \frac{\pi_\theta}{\pi_{ref}})^2$

$k_3 = \frac{\pi_{ref}}{\pi_\theta} - \ln \frac{\pi_{ref}}{\pi_\theta} - 1$

至此，针对2.3提出的核心问题——如何高效且低偏地估计期望回报 $b^*(x)$，本节给出了一种统计学上更直观的解法。通过局部分布条件下组采样，以经验均值估计样本基线，给出一套在长推理场景下强化学习提供计算可行性更高、优化稳定性更高的路径

3.1

But, wait, wait, wait. Let us check again

让我们重新 check. 2.1一开始给出的目标函数

$$\max_{\theta \in \mathbb{R}^d} J(\theta; x) \triangleq \sum_{y \in \mathcal{Y}} \pi_\theta(y|x) r(x,y) - \beta \mathbb{D}_{KL}(\pi_\theta(\cdot|x) \| \pi_{ref}(\cdot|x))$$

No. Akivian

Date

公式中存在一个明显的限制条件"θ"

从一开始，我们就下意识地假定限制策略是一个由连续参数 $\theta \in \mathbb{R}^d$ 控制的神经网络 π_θ

but，如果移除这一限制呢？

$$\max_{\theta \in \mathbb{R}^d} J(\theta; x) \triangleq \sum_{y \in \mathcal{Y}} \pi_\theta(y|x) r(x,y) - \beta \mathbb{D}_{kl}(\pi_\theta(\cdot|x) \| \pi_{ref}(\cdot|x))$$

$$\max_{\pi \in \Pi} J_{global}(\pi) \triangleq \mathbb{E}_{x \sim D}\left[\sum_{y \in \mathcal{Y}} \pi(y|x) r(x,y) - \beta \mathbb{D}_{kl}(\pi(\cdot|x) \| \pi_{ref}(\cdot|x))\right]$$

其中，相关空间与函数的形式化定义如下：

输入空间：提示词空间 $\mathcal{X}$，其上附带先验概率测度 $x \sim D$；

输出空间：离散候选序列空间 $\mathcal{Y}$，其上的概率单纯形记为 $\Delta(\mathcal{Y})$；

全策略空间（马尔可夫转移核空间）：

$$\Pi \triangleq \{\pi : \mathcal{X} \to \Delta(\mathcal{Y})\} = \prod_{x \in \mathcal{X}} \Delta(\mathcal{Y})$$

（Π 为所有可能的条件概率分布构成的笛卡尔积空间）

基准参考策略：$\pi_{ref} \in \Pi$，具备全支撑性（$\forall x \in \mathcal{X}, y \in \mathcal{Y}, \pi_{ref}(y|x) > 0$）

∵非参数化后，策略空间为具备笛卡尔乘积结构，各输入提示词 x 对应条件分布 $\pi(\cdot|x)$ 彼此独立，无交叉约束，因此，最大化全局期望等价于，对数据集上的每一个 x，独立求解 $J(\pi; x)$ 的极大值。

$$\pi^*(\cdot|x) = \arg\max_{\pi(\cdot|x) \in \Delta_{\mathcal{Y}}} J(\pi; x).$$

其中条件目标函数为：

$$J(\pi; x) \triangleq \sum_{y \in \mathcal{Y}} \pi(y|x) r(x,y) - \beta \sum_{y \in \mathcal{Y}} \pi(y|x) \ln \frac{\pi(y|x)}{\pi_{ref}(y|x)} \quad s.t. \sum_{y \in \mathcal{Y}} \pi(y|x) = 1, \pi(y|x) \geq 0$$

KOKUYO

No. Akivian

Date

所研究的问题转换为对固定上下文x的代数极值问题

这意味着，我们可以通过代数变换

直接求出最优策略 π^* 的解析解！

3.2

由引理2：

当且仅当：

$$\pi(y|x) = \pi^*(y|x) = \frac{1}{Z(x)} \cdot \pi_{ref}(y|x) \exp\left(\frac{1}{\beta} r(x,y)\right) 时$$

这里 $J(\pi)$ 取最大值 $\beta \ln Z(x)$

but. 虽然我们求出了最优策略的解析解式，却无法实际使用

i) 奖励函数 $r(x,y)$，无法获得解析表达

ii) $Z(x)$ 无法精确求解：求和空间 Y 的阶为 $O(|V|^L)$（$|V|$ 为词表大小，L 为序列长度）NP-hard

事实上，在2.1~2.5节，就是试图使用各种方法逼近该理论解析解

既然 $r(x,y)$，$Z(x)$ 均无法精确表示/计算，这条路走不通吗？

让我们回顾最开始的问题与假设：

已知人类相对偏好数据集 $\mathcal{D}_{pref} = \{(x, y_w, y_l)\}$

假定人类在给定上下文 x 下对两个候选输出 (y_w, y_l) 的判别决策遵循 Bradley-Terry (BT) 二分类选择模型：

$$p^*(y_w \succ y_l | x) = \sigma(r^*(x, y_w) - r^*(x, y_l))$$

$$\sigma(z) \triangleq \frac{1}{1+e^{-z}}$$

又已知：$\pi^*(y|x) = \frac{1}{Z(x)} \cdot \pi_{ref}(y|x) \exp\left(\frac{1}{\beta} r(x,y)\right)$.

故.最核心的问题是:

已知: $\pi_{ref}(y|x)$参考策略, 偏好样本D_{pref}(体现真实偏好概率p^*)

$$p^*(y_w \succ y_l|x) = \sigma(r^*(x,y_w) - r^*(x,y_l)) \quad ①$$

$$\pi^*(y|x) = \frac{1}{Z(x)} \cdot \pi_{ref}(y|x)\exp(\frac{1}{\beta} r(x,y)) \quad ②$$

求关于π^*的方程

嗯? 相对关系? 两方程作差?

这让人想起高中圆锥曲线中的点差法:

已知方程$\frac{x^2}{a^2}+\frac{y^2}{b^2}=1$. 两点$A(x_1,y_1)$ $B(x_2,y_2)$均在椭圆上.

代入方程 $\begin{cases} \frac{x_1^2}{a^2}+\frac{y_1^2}{b^2}=1 \\ \frac{x_2^2}{a^2}+\frac{y_2^2}{b^2}=1 \end{cases}$

两式相减消去右边"常数"

得到 $\frac{(x_1-x_2)(x_1+x_2)}{a^2} + \frac{(y_1-y_2)(y_1+y_2)}{b^2} = 0$

进一步得到 $k=\frac{y_1-y_2}{x_1-x_2} = -\frac{b^2}{a^2}\cdot\frac{x_1+x_2}{y_1+y_2}$. 记中点坐标为$(x_0,y_0)$

得 $k_{AB}\cdot\frac{y_0}{x_0} = -\frac{b^2}{a^2}$

类似地, 既然$Z(x)$难以计算求解, 且$Z(x)$为相对y的"常数"

是否可以通过类似的思路将其直接消去?

对②式两边同取自然对数 $\ln\pi^*(y|x) = \ln\left(\frac{1}{Z(x)}\cdot\pi_{ref}(y|x)\exp(\frac{1}{\beta}r^*(x,y))\right)$

$$= \ln\pi_{ref}(y|x) + \frac{1}{\beta}r^*(x,y) - \ln Z(x)$$

整理可得

$$r^*(x,y) = \beta\ln\left(\frac{\pi^*(y|x)}{\pi_{ref}(y|x)}\right) + \boxed{\beta\ln Z(x)}$$

故 $r^*(x,y_w)-r^*(x,y_l)=\left[\beta\ln\left(\frac{\pi^*(y_w|x)}{\pi_{ref}(y_w|x)}\right)+\beta\ln Z(x)\right]-\left[\beta\ln\left(\frac{\pi^*(y_l|x)}{\pi_{ref}(y_w|x)}\right)+\beta\ln Z(x)\right]$

$$=\beta\ln\left(\frac{\pi^*(y_w|x)}{\pi_{ref}(y_w|x)}\right)-\beta\ln\left(\frac{\pi^*(y_l|x)}{\pi_{ref}(y_l|x)}\right)$$

代入①式 $$p^*(y_w\succ y_l|x)=\sigma\left(\beta\ln\frac{\pi^*(y_w|x)}{\pi_{ref}(y_w|x)}-\beta\ln\frac{\pi^*(y_l|x)}{\pi_{ref}(y_l|x)}\right)$$

以参数化神经网络策略 π_θ 拟合最优策略 π^*，将 π_θ 代入上述偏好表达式，定义模型预测的偏好概率为

$$p_\theta(y_w\succ y_l|x)\triangleq\sigma\left(\beta\ln\frac{\pi^*(y_w|x)}{\pi_{ref}(y_w|x)}-\beta\ln\frac{\pi^*(y_l|x)}{\pi_{ref}(y_l|x)}\right)$$

根据统计学习准则，在给定偏好数据集 D_{pref} 上，通过极大似然估计(MLE)优化参数 θ

$$\mathcal{L}_{DPO}(\theta;\pi_{ref})\triangleq-\mathbb{E}_{(x,y_w,y_l)\sim D_{pref}}\left[\ln p_\theta(y_w\succ y_l|x)\right]$$

将模型预测的偏好概率代入上式，导出最终损失函数

$$\mathcal{L}_{DPO}(\theta;\pi_{ref})=-\mathbb{E}_{(x,y_w,y_l)\sim D_{pref}}\left[\ln\sigma\left(\beta\ln\frac{\pi^*(y_w|x)}{\pi_{ref}(y_w|x)}-\beta\ln\frac{\pi^*(y_l|x)}{\pi_{ref}(y_l|x)}\right)\right]$$

下对参数 θ 求梯度，以分析该损失函数优化机制，定义模型隐含的奖励估计量为：

$$\hat{r}_\theta(x,y)\triangleq\beta\ln\frac{\pi_\theta(y|x)}{\pi_{ref}(y|x)}$$

利用Sigmoid函数求导性质

$$\nabla_z\ln\sigma(z)=1-\sigma(z)=\sigma(-z)$$

对 L_{DPO} 应用链式求导

$$\nabla_\theta L_{DPO}(\theta) = -\mathbb{E}_{(x,y_w,y_l)}\left[\sigma(\hat{r}_\theta(x,y_l)-\hat{r}_\theta(x,y_w))\cdot\nabla_\theta(\beta\ln\pi_\theta(y_w|x)-\beta\ln\pi_\theta(y_l|x))\right]$$

$$= -\beta\mathbb{E}_{(x,y_w,y_l)}\Big[\underbrace{\sigma(\hat{r}_\theta(x,y_l)-\hat{r}_\theta(x,y_w))}_{\text{自适应权重 }w}\cdot\big(\underbrace{\nabla_\theta\ln\pi_\theta(y_w|x)}_{\text{推向胜出项概率}}-\underbrace{\nabla_\theta\ln\pi_\theta(y_l|x)}_{\text{压低失败项概率}}\big)\Big]$$

该梯度具有两个直观性质

1> 更新方向明确：梯度直接把提高胜出项 y_w 概率，压低失败项 y_l 生成概率方向更新

2> 自适应加权：前置权重 $w=\sigma(\hat{r}_l-\hat{r}_w)$ 本质上度量了当前预测偏差。

若模型当前完全判断错误（$\hat{r}_l \gg \hat{r}_w$），权重因子 $w\to 1$，施加较大梯度进行纠正；

若模型已能很好区分偏好（$\hat{r}_w \gg \hat{r}_l$），则 $w\to 0$，梯度自然衰减，防止过拟合

至此，通过反解最优策略解析解，结合 Bradley-Terry 偏好模型假设，我们找到了一种在特定假设下（满足BT模型，真实奖励与最优策略可获得，RLHF最优策略在偏好上与人类标签同向）与第2章"显式奖励+在线RL"方法，在目标上数学等价的直接优化方法

通过"隐式奖励+离线监督"，从而以简洁直接的方式，利用人类相对偏好数据，训练模型生成更受偏好的回答，从而回应了初始问题。

but. 必须指出的是第3章给出的方法建立在一系列理想化假设上

i> 人类偏好服从 Bradley-Terry 模型，即偏好概率由奖励差值决定，且偏好具有传递性（但真实数据常常不满足，甚至自相矛盾）

ii> 可实现性：真实奖励函数 r^* 位于奖励模型类中，且最优策略 π^* 也能被策略模型类表示。（可能导致 Misspecification）

iii> RLHF最优策略偏好人类偏好响应：事实上DPO第3章方法的等价性是**条件性的而非普遍的**，若不满足以上两个条件，则方法优化的便不再是RLHF原始目标

正因如此，第2章探索出的路径（在线强化学习范式）在推理大模型训练中，依然具有不可替代优势（自发展开回溯、反思、自我纠错，与以时间计算换取的有效手段）

No. Akivian

Date

另，

在最后，我们(开心^▽^)以更广为人知的方式重新介绍前文推导得出的各个算法.

§1 策略梯度与REINFORCE算法 [Williams, 1992]

策略梯度定理 [Sutton et al., 1999]

§2.4 经典PPO-RLHF

偏好强化学习 [Christiano et al., 2017]

广义优势估计(GAE) [Schulman et al, 2018]

近端策略优化(PPO) [Schulman et al., 2017]

工业标准落地·InstructGPT: [Ouyang et al., 2022]

§2.5 GRPO [Shao et al., 2024]

§3 DPO [Rafailov et al., 2023]

感谢前辈们的探索与开拓。

Author: Akivian

Repo: github.com/Akivian

Date: 2026.10